

## Введение

В парадигме статистической обработки сигналов (Krim, Viberg, 1996; Godara, 1997) важную роль играет задача оценивания угловых координат (DoA) источников сигналов. Существуют две категории методов для оценивания угловых координат: подпространственные (к примеру, MUSIC, ESPRIT), основанные на разбиении ковариационной матрицы наблюдений на подпространство, соответствующее сигналу, и подпространство, соответствующее шуму, и методы, основанные на поиске ММП-оценки. Последние оказываются особенно полезными в постановках задач, предполагающих относительно низкое отношение сигнал-шум, корреляцию между сигналами или малое число наблюдений.

Одним из классических методов нахождения оценки максимального правдоподобия является ЕМ-алгоритм [1] (Dempster, Laird, Rubin, 1977). В практических приложениях зачастую используются модификации этого алгоритма, позволяющие упростить оптимизацию на М-шаге (ЕСМ-алгоритм, Meng, Rubin, 1993), либо обеспечивающие более быструю сходимость (SAGE-алгоритм, Fessler, Hero, 1994), и подобные методы уже применяются для оценивания угловых координат источников (Feder, Weinstein, 1988; Miller, Fuhrmann, 1990; Gong, Lyu, 2021). Данные алгоритмы используют предположение об известном шуме. В последние годы, начали появляться статьи (Gong, Lyu, 2023), посвященные использованию ЕМ-алгоритма в условиях равномерного (по сенсорам) неизвестного шума. В подобных алгоритмах, как правило, на М-шаге происходит вычисление сразу несколько групп параметров, к примеру, могут быть вычислены угловые координаты и ковариационная матрица сигналов.

В реальных условиях эксплуатации сенсоры могут быть подвержены стохастическим аппаратным сбоям, вследствие чего их показания в определенные моменты времени могут не быть надежными.

В работе формулируется задача поиска оптимальных угловых координат источников сигналов в условиях, когда часть сенсоров подвержены аппаратным сбоям или случайным помехам, и, ввиду этого, часть наблюдений содержит случайные пропуски. Используется стохастическая модель сигнала, шум предполагается известным и диагональным. Сигнал и шум предполагаются независимыми и имеющими комплексное нормальное распределение. В качестве скрытых переменных рассматриваются исходные сигналы и пропуски в наблюдениях. Ввиду чувствительности ЕМ-алгоритма к инициализации, используется мультистарт, для первой итерации используется оценка, полученная алгоритмом MUSIC, на последующих - случайные смещения указанной оценки. В условиях, когда число сенсоров оказывается меньше числа наблюдений, причем порядка трети сенсоров ненадежны, оценки, полученные с помощью алгоритма MUSIC оказываются существенно смещены, предложенный в работе ЕМ-алгоритм позволяет получить оценки угловых координат, для которых характерно значительно меньшее смещение относительно истинных значений параметров.

## 1 Постановка задачи

Предположим, имеется линейная антенная решетка, состоящая из  $L$  сенсоров, которая принимает узкополосные сигналы, направленные из  $K$  источников, причем  $K < L$ . Этим источникам соответствуют угловые координаты (DoA)  $\theta$ , практически не изменяющиеся во времени. По итогам измерений было получено  $T$  снимков полученного сигнала, причем ввиду стохастических технических сбоев, связанных с сенсорами, большая часть таких снимков содержит помимо надежных данных ненадежные, которые в рамках данной задачи рассматриваются как пропуски. Пусть  $X$  — набор наблюдений, полученных сенсорами в моменты времени  $t = 1, \dots, T$ ,  $X_t$  соответствует наблюдению в момент времени  $t$ , через  $x$  и  $x_t$  будем обозначать реализации полного набора наблюдений и наблюдения в отдельный момент времени  $t$  соответственно. Ввиду наличия пропусков в данных, будем считать, что набор наблюдений  $X$  состоит из доступной части  $X_o = \{X_{t,o_t}\}_{t=1}^T$  и недоступной:  $X_m = \{X_{t,m_t}\}_{t=1}^T$ , причем  $o_t \cup m_t = \{1, \dots, T\}$ ,  $o_t \cap m_t = \emptyset$ ,  $\forall t \in \{1, \dots, T\}$ . Пред-

полагается, что  $\nexists o_t : o_t = \emptyset$ , т.е. нет таких наблюдений, которые состоят лишь из недоступной части.

Набор  $X$  является результатом следующей модели наблюдений:

$$X = AS + N, \quad (1)$$

где

$$X = [X_1, \dots, X_T], S = [S_1, \dots, S_T], N = [N_1, \dots, N_T], \quad (2)$$

и  $X_t \in \mathbb{C}^L, S_t \in \mathbb{C}^K, N_t \in \mathbb{C}^L$  – векторы-столбцы, соответствующие наблюдениям, источникам и шумам в момент времени  $t = 1, \dots, T$ ,  $A$  – матрица векторов направленности для равномерного линейного массива:

$$A(\theta) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-2j\pi \frac{d}{\lambda} \sin(\theta_1)} & e^{-2j\pi \frac{d}{\lambda} \sin(\theta_2)} & \dots & e^{-2j\pi \frac{d}{\lambda} \sin(\theta_K)} \\ \dots & \dots & \ddots & \vdots \\ e^{-2j\pi(L-1) \frac{d}{\lambda} \sin(\theta_1)} & e^{-2j\pi(L-1) \frac{d}{\lambda} \sin(\theta_2)} & \dots & e^{-2j\pi(L-1) \frac{d}{\lambda} \sin(\theta_K)} \end{bmatrix}. \quad (3)$$

Возможны следующие варианты для шума и сигнала в наблюдениях:

Сигнал $S$	Шум $N$
Детерминированный	Стохастический
Стохастический	Стохастический

## 2 Детерминированный сигнал и стохастический шум

См. папку

## 3 Стохастический сигнал и шум

Пусть сигналы, испускаемые источниками, шумы на сенсорах и наблюдения предполагаются стохастическими:  $S_t \sim \mathcal{CN}(\mathbf{0}_{K \times 1}, \Gamma)$ ,  $N_t \sim \mathcal{CN}(\mathbf{0}_{L \times 1}, \Lambda)$ ,  $X_t \sim \mathcal{CN}(\mathbf{0}_{L \times 1}, A\Gamma A^* + \Lambda)$ ,  $t = 1, \dots, T$ . Матрицы  $\Gamma$  и  $\Lambda$  предполагаются диагональными, т.е. сигналы не коррелированы между собой, шумы также не коррелированы между собой, в любой момент времени  $S_t \perp N_t$ . Составим ЕМ-алгоритм для случая известного шума.

### 3.1 Описание алгоритма

Воспользуемся ЕМ-алгоритмом для того, чтобы определить значения параметров  $\Upsilon = (\theta, \Gamma)$ ,  $\Xi = (X_m, S)$  – латентные переменные (недоступные значения и сигналы). Пусть  $\Xi_t = (X_{t,m_t}, S_t)$  – набор латентных переменных, соответствующих наблюдению  $X_t$ , причем для отдельных наблюдений  $X_{t,m_t} = \emptyset$ .

#### ЕМ-алгоритм

- **Е-шаг** Найти математическое ожидание полоного правдоподобия с учетом апосториорного распределения латентных переменных:

$$\mathbb{E}_{q(\Xi)} [\log P(X, S)],$$

где

$$q(\Xi) = P(X_m, S | X_o = x_o, \Upsilon^{(\tau-1)}).$$

• М-шаг

$$\Upsilon^{(\tau)} = \arg \max_{\Upsilon} \mathbb{E}_{q(\Xi)} [\log P(X, S)].$$

Наблюдения  $X_t, t = 1, \dots, T$  предполагаются независимыми и одинаково распределенными.

Требуется найти математическое ожидание полного правдоподобия с учетом текущей оценки параметров и апостериорного совместного распределения пропущенных значений в наблюдениях  $X_m$  и сигналов  $S$

$$\mathbb{E}_{(X_m, S) | X_o = x_o, \Upsilon^{(\tau-1)}} [\log P(X, S)]. \quad (4)$$

Преобразуем выражение, учитывая тот факт, что наблюдения являются независимыми, и обозначив через  $\mathcal{I}$  условную информацию  $X_o = x_o, \Upsilon^{(\tau-1)}$  и через  $\mathcal{I}_t$  условную информацию  $X_{t,o_t} = x_{t,o_t}, \Upsilon^{(\tau-1)}$ :

$$\begin{aligned} \mathbb{E}_{q(\Xi)} [\log P(X, S)] &= \\ \mathbb{E}_{q(\Xi)} [\log P(X|S) + \log P(S)] &= \\ \left[ \sum_{t=1}^T \mathbb{E}_{(X_{t,m_t}, S_t) | \mathcal{I}_t} \log [P(X_t | S_t)] + \sum_{t=1}^T \mathbb{E}_{(X_{t,m_t}, S_t) | \mathcal{I}_t} [\log P(S_t)] \right] &= \\ -T \left[ \log |\Lambda| + \text{Tr} (\Lambda^{-1} \mathbb{E}_{q(\Xi)} [XX^*]) - 2 \text{Tr} (\Lambda^{-1} A(\theta) \mathbb{E}_{q(\Xi)} [XS^*]) \right. & \\ \left. + \text{Tr} (\Lambda^{-1} A(\theta) \mathbb{E}_{q(\Xi)} [SS^*] A^*(\theta)) + \log |\Gamma| + \text{Tr} (\Gamma^{-1} \mathbb{E}_{q(\Xi)} [SS^*]) \right]. \end{aligned}$$

Выражение  $\mathbb{E}_{(X_{t,m_t}, S_t) | \mathcal{I}_t} [\cdot]$  соответствует случаю максимально полного набора латентных переменных: некоторые наблюдения в наборе могут не содержать пропуски ( $X_{t,m_t} = \emptyset$ ), и тогда это выражение упрощается до  $\mathbb{E}_{S_t | \mathcal{I}_t} [\cdot]$ . Для нахождения условных моментов, указанных в формуле выше, требуется найти апостериорное распределение скрытых переменных.

### 3.2 Апостериорное распределение латентных переменных для неполных наблюдений

Распределение  $P(X_{t,m_t}, S_t | X_{t,o_t})$  задается однозначно ввиду того, что:

1.  $S_t \perp N_t$ ;
2.  $A$  – матрица линейного преобразования;
3.  $S_t, N_t$  имеют нулевую псевдоковариацию и нулевое математическое ожидание.

Подобная формулировка будет улучшена и дополнена источником, это предложение и предшествующее ему – только для чернового варианта!

Сначала найдем апостериорное распределение  $P(X_m | \mathcal{I})$ . Для достижения этой цели, для каждой пары  $\{(o_t, m_t) : m_t \neq \emptyset\}$  создадим разбиение оценки ковариационной матрицы наблюдений  $\hat{R}$  на блоки, индуцированное этим разбиением множества индексов, оно имеет следующий вид:

$$\hat{R} = \begin{pmatrix} \hat{R}_{o_t, o_t} & \hat{R}_{o_t, m_t} \\ \hat{R}_{m_t, o_t} & \hat{R}_{m_t, m_t} \end{pmatrix}, \quad (5)$$

где каждый блок определяется как

$$\hat{R}_{a,b} = (\hat{R}_{ij})_{i \in a, j \in b}.$$

Для каждого наблюдения, содержащего пропуски, требуется найти апостериорное распределение пропущенных значений,  $P(X_{t,m_t} | X_{t,o_t} = x_{t,o_t}, \Upsilon^{(\tau-1)})$ ,  $t = 1, \dots, T$ ,  $m_t \neq \emptyset$ . Обозначим через  $\mathcal{I}_t$  условную информацию  $X_{t,o_t} = x_{t,o_t}, \Upsilon^{(\tau-1)}$ . Параметры апостериорного распределения

$\mathbb{P}(X_{t,m_t} | \mathcal{I}_t), t = 1, \dots, T$  на итерации  $\tau$  можно найти следующим образом:

$$\begin{cases} \mathbb{E}[X_{t,m_t} | \mathcal{I}_t] = \hat{\mathbf{R}}_{m_t, o_t} \left( \hat{\mathbf{R}}_{o_t, o_t} \right)^{-1} \cdot x_{t,o_t}, \\ \text{Cov}(X_{t,m_t} | \mathcal{I}_t) = \hat{\mathbf{R}}_{m_t, m_t} - \hat{\mathbf{R}}_{m_t, o_t} \left( \hat{\mathbf{R}}_{o_t, o_t} \right)^{-1} \hat{\mathbf{R}}_{o_t, m_t}, \end{cases} \quad (6)$$

где  $\hat{\mathbf{R}}_{o_t, o_t} = \hat{\mathbf{R}}_{o_t, o_t}^{(\tau-1)}$ ,  $\hat{\mathbf{R}}_{o_t, m_t} = \hat{\mathbf{R}}_{o_t, m_t}^{(\tau-1)}$ ,  $\hat{\mathbf{R}}_{m_t, o_t} = \hat{\mathbf{R}}_{m_t, o_t}^{(\tau-1)}$ ,  $\hat{\mathbf{R}}_{m_t, m_t} = \hat{\mathbf{R}}_{m_t, m_t}^{(\tau-1)}$ .

Для каждого наблюдения  $X_t$ , содержащего пропуски, оценим условный второй начальный момент  $\mathbb{E}[X_t X_t^* | \mathcal{I}_t]$ :

$$\begin{aligned} \mathbb{E}[X_t X_t^* | \mathcal{I}_t] &= \mathbb{E}[X_t | \mathcal{I}_t] \cdot \mathbb{E}[X_t^* | \mathcal{I}_t] + \text{Cov}(X_t | \mathcal{I}_t) \\ &= \mathbb{E}[X_t | \mathcal{I}_t] \cdot \mathbb{E}[X_t^* | \mathcal{I}_t] + \begin{pmatrix} \mathbf{O}_{o_t, o_t} & \mathbf{O}_{o_t, m_t} \\ \mathbf{O}_{m_t, o_t} & \text{Cov}(X_t, m_t | \mathcal{I}_t) \end{pmatrix}, \end{aligned}$$

где  $\mathbf{O}_{o_t, o_t}$ ,  $\mathbf{O}_{o_t, m_t}$ ,  $\mathbf{O}_{m_t, o_t}$  – нулевые блочные матрицы. Разбиение указанной матрицы на четыре блока, три из которых состоят из нулей, индуктировано разбиением множества индексов  $\{1, \dots, L\}$  на множества  $o_t, m_t$ .

Параметры апостериорного распределения  $P(S_t | \mathcal{I}_t), t = 1, \dots, T$  можно найти следующим образом:

$$\begin{cases} \mathbb{E}[S_t | \mathcal{I}_t] = \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbb{E}[X_t | \mathcal{I}_t], \\ \text{Cov}(S_t | \mathcal{I}_t) = \mathbf{A} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma} + \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \text{Cov}(X_t | \mathcal{I}_t) \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}, \end{cases} \quad (7)$$

где  $\mathbf{A} = \mathbf{A}(\theta^{(\tau-1)})$ ,  $\boldsymbol{\Gamma} = \boldsymbol{\Gamma}^{(\tau-1)}$ ,  $\hat{\mathbf{R}} = \hat{\mathbf{R}}^{(\tau-1)}$ . Для вывода этих формул используются свойство башни условного математического ожидания (tower property) и закон полной дисперсии (подробности приведены в приложении Б).

Оценим  $\mathbb{E}_{(X_t, m_t, S_t) | \mathcal{I}_t} [S_t S_t^*]$ :

$$\mathbb{E}_{(X_t, m_t, S_t) | \mathcal{I}_t} [S_t S_t^*] = \mathbb{E}[S_t | \mathcal{I}_t] \cdot \mathbb{E}[S_t^* | \mathcal{I}_t] + \text{Cov}(S_t | \mathcal{I}_t), \quad (8)$$

Оценим  $\mathbb{E}_{(X_t, m_t, S_t) | \mathcal{I}_t} [X_t S_t^*]$ :

$$\mathbb{E}_{(X_t, m_t, S_t) | \mathcal{I}_t} [X_t S_t^*] = \mathbb{E}[X_t X_t^* | \mathcal{I}_t] \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}, \quad (9)$$

где  $\mathbf{A} = \mathbf{A}(\theta^{(\tau-1)})$ ,  $\hat{\mathbf{R}} = \hat{\mathbf{R}}^{(\tau-1)}$ ,  $\boldsymbol{\Gamma} = \boldsymbol{\Gamma}^{(\tau-1)}$ .

### 3.3 Апостериорное распределение латентных переменных для полных наблюдений

Если  $m_t = \emptyset$ , то апостериорное распределение упрощается следующим образом:  $\mathbb{P}(X_{t,m_t}, S_t | \mathcal{I}_t) = \mathbb{P}(S_t | \mathcal{I}_t)$ . Параметры апостериорного распределения  $\mathbb{P}(S_t | \mathcal{I}_t), t = 1, \dots, T$ :

$$\begin{cases} \mathbb{E}[S_t | \mathcal{I}_t] = \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbb{E}[X_t | \mathcal{I}_t], \\ \text{Cov}(S_t | \mathcal{I}_t) = \mathbf{A} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}. \end{cases} \quad (10)$$

При этом:

$$\mathbb{E}_{S_t | \mathcal{I}_t} [X_t X_t^*] = \mathbb{E}[X_t | \mathcal{I}_t] \cdot \mathbb{E}[X_t^* | \mathcal{I}_t] = x_t x_t^*, \quad (11)$$

$$\mathbb{E}_{S_t | \mathcal{I}_t} [X_t S_t^*] = \mathbb{E}[X_t | \mathcal{I}_t] \cdot \mathbb{E}[S_t^* | \mathcal{I}_t] = x_t \cdot \mathbb{E}[S_t^* | \mathcal{I}_t] = x_t \cdot x_t^* \cdot \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}, \quad (12)$$

$$\mathbb{E}_{S_t | \mathcal{I}_t} [S_t S_t^*] = \mathbb{E}[S_t | \mathcal{I}_t] \cdot \mathbb{E}[S_t^* | \mathcal{I}_t] + \text{Cov}(S_t | \mathcal{I}_t). \quad (13)$$

### 3.4 Е-шаг, Агрегация

Теперь оценим вторые начальные моменты  $\mathbb{E}_{q(\Xi)}[XX^*]$ ,  $\mathbb{E}_{q(\Xi)}[SS^*]$ ,  $\mathbb{E}_{q(\Xi)}[XS^*]$ :

$$\mathbb{E}_{q(\Xi)}[XX^*] = \frac{1}{T} \sum_{t=1}^T \mathbb{E}[X_t X_t^* | \mathcal{I}_t], \quad (14)$$

$$\mathbb{E}_{q(\Xi)}[SS^*] = \frac{1}{T} \sum_{t=1}^T \mathbb{E}_{q(\Xi_t)}[S_t S_t^*], \quad (15)$$

$$\mathbb{E}_{q(\Xi)}[XS^*] = \frac{1}{T} \sum_{t=1}^T \mathbb{E}_{q(\Xi_t)}[X_t S_t^*]. \quad (16)$$

### 3.5 М-шаг

Требуется найти наилучшую оценку параметров, решив следующую задачу оптимизации:

$$\begin{aligned} \Upsilon^{(\tau)} &= \arg \max_{\Upsilon} \mathbb{E}_{q(\Xi)}[\log P(X, S)] = \\ &\arg \min_{\Upsilon} T \left[ \log |\Lambda| + \text{Tr}(\Lambda^{-1} \mathbb{E}_{q(\Xi)}[XX^*]) - 2 \text{Tr}(\Lambda^{-1} A(\theta) \mathbb{E}_{q(\Xi)}[XS^*]) \right. \\ &\quad \left. + \text{Tr}(\Lambda^{-1} A(\theta) \mathbb{E}_{q(\Xi)}[SS^*] A^*(\theta)) + \log |\Gamma| + \text{Tr}(\Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*]) \right]. \end{aligned}$$

Оценим угловые координаты источников  $\theta$ :

$$\begin{aligned} \theta^{(\tau)} &= \arg \min_{\theta} Q_1(\theta | \theta^{(\tau-1)}) = \arg \min_{\theta} \left[ -2 \text{Tr}(\Lambda^{-1} A(\theta) \mathbb{E}_{q(\Xi)}[XS^*]) \right. \\ &\quad \left. + \text{Tr}(\Lambda^{-1} A(\theta) \mathbb{E}_{q(\Xi)}[SS^*] A^*(\theta)) \right] = \\ &\arg \min_{\theta} \|\Lambda^{-1/2} (\mathbb{E}_{q(\Xi)}[XS^*] - A(\theta) \mathbb{E}_{q(\Xi)}[SS^*])\|_F^2. \end{aligned}$$

Эту задачу можно решить численно, подробности приведены в приложении 3.

Оценим ковариацию сигналов  $\Gamma$  с учетом предположения о некоррелированности сигналов:

$$\Gamma^{(\tau)} = \arg \min_{\Gamma} Q_2(\Gamma | \Gamma^{(\tau-1)}) = T \left[ \log |\Gamma| + \text{Tr}(\Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*]) \right] = \mathcal{D} \left[ \mathbb{E}_{q(\Xi)}[SS^*] \right].$$

Обновляем оценку ковариации наблюдений с учетом полученных оценок параметров:

$$\hat{\mathbf{R}}^{(\tau)} = A(\theta^{(\tau)}) \Gamma^{(\tau)} A^*(\theta^{(\tau)}) + \Lambda. \quad (17)$$

## 4 Результаты численного эксперимента

### 4.1 Первый набор начальных условий

$L = 25, K = 1, T = 12, 5$  сенсоров неисправны, 50% пропусков для каждого из них,  
 $\Gamma = 0.5 \cdot E_K, \Lambda = 8.1 \cdot E_L, \theta = [0.7] \approx [40.107^\circ]$ .

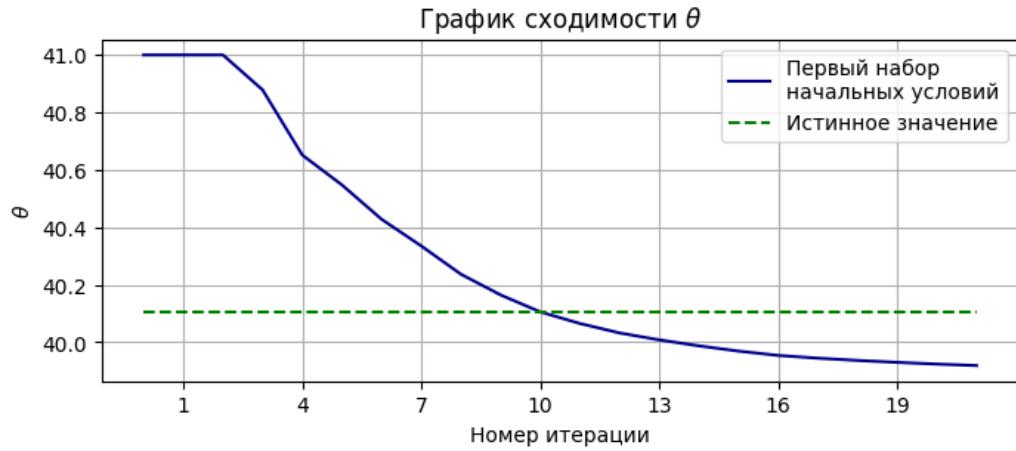


Рис. 1: График сходимости угловой координаты для первого набора начальных условий

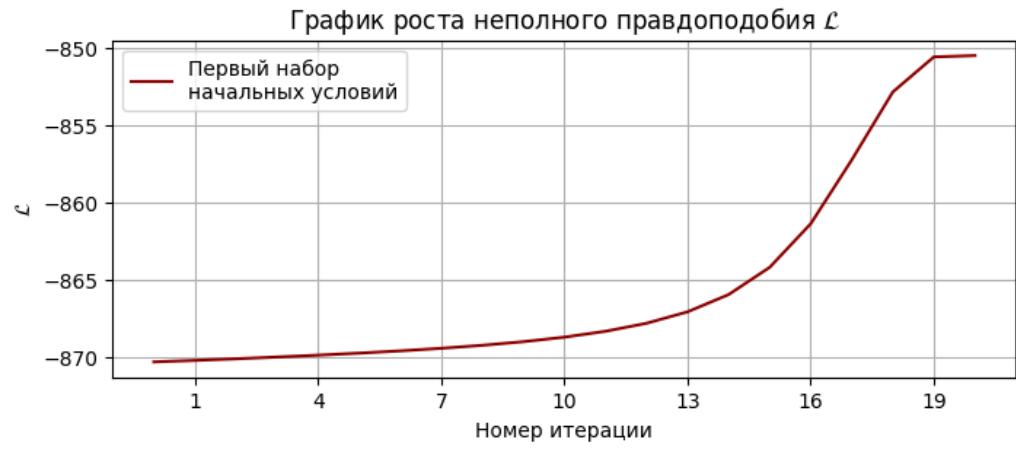


Рис. 2: График роста  $\log P(X_o | \Upsilon)$  для первого набора начальных условий

## 4.2 Второй набор начальных условий

$L = 25, K = 1, T = 11, 8$  сенсоров неисправны, 50% пропусков для каждого из них,  
 $\Gamma = 0.5 \cdot E_K, \Lambda = 6.1 \cdot E_L, \theta = [0.7] \approx [40.107^\circ]$ .

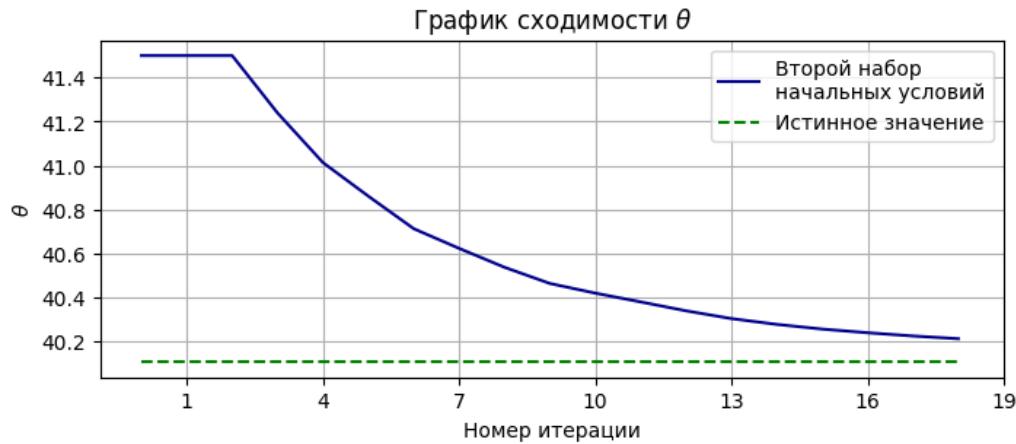


Рис. 3: График сходимости угловой координаты для второго набора начальных условий

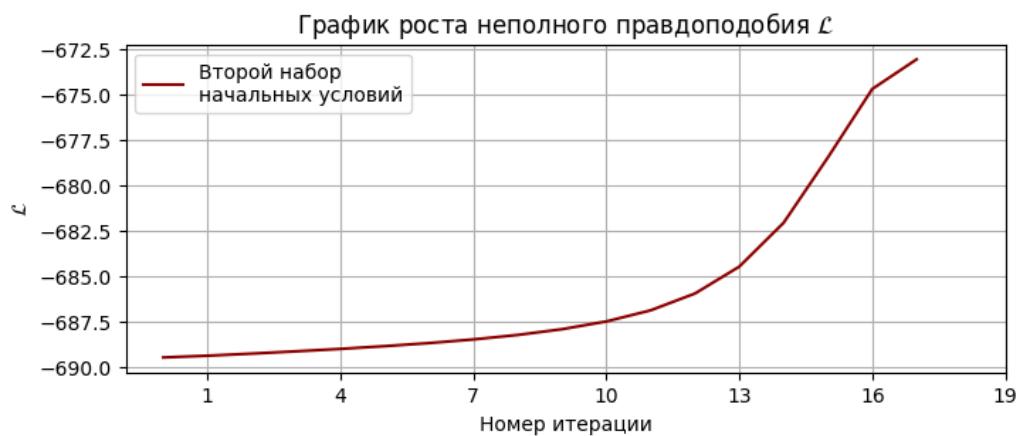


Рис. 4: График роста  $\log P(X_o | \Upsilon)$  для второго набора начальных условий

## Приложение А. Инициализация

Оценим ковариационную матрицу  $\hat{R}^{(0)}$  следующим образом: если  $\sum_t \mathbf{I}_{x_t=x_{t,o}} \geq L$ , оцениваем  $\hat{R}^{(0)}$  по выборке, образованной  $x_t : x_t = x_{t,o}$ . В противном случае используется следующий подход: пусть  $x^l$  – строка матрицы  $X$ , соответствующая сенсору  $l, l = 1, \dots, L$ ,  $x_o^l$  – выборка, образованная доступными наблюдениями в строке  $l$ ,  $x_m^l$  – выборка, образованная недоступными наблюдениями в строке  $l$ ,  $x_t^l$  – компонента наблюдения  $x_t$ , соответствующая сенсору  $l$ . Для всех недоступных значений построим следующую оценку: если  $x_t^l \in x_m^l, l = 1, \dots, L, t = 1, \dots, T$ , то  $\hat{x}_t^l = \bar{x}_o^l$ . Оцениваем ковариацию по такому оцененному набору  $\hat{x}$ :

$$\hat{R}^{(0)} = \text{Cov}(\hat{x}). \quad (18)$$

Оценим вектор угловых координат источников  $\theta^{(0)}$  следующим образом:

- Выберем число  $\nu$ , которое будет соответствовать первому компоненту вектора  $\theta^{(0)}$ :

$$\nu \sim \mathcal{U}(-\pi; \pi); \quad (19)$$

- Оценим компоненты вектора  $\theta^{(0)}$  так:  $\theta_i^{(0)} = (\nu + (i-1) \cdot \frac{2\pi}{K}) \bmod 2\pi, i = 1, \dots, K$ . При этом,  $a \bmod b = a - b \cdot \lfloor \frac{a}{b} \rfloor$ .

Альтернативный подход: используем  $\hat{R}^{(0)}$  для оценки  $\theta^{(0)}$  с помощью алгоритма MUSIC, используем эту оценку на первой итерации мультистарта EM, на следующих используем оценки в окрестности указанной.

Начальную ковариацию сигналов  $\Gamma^{(0)}$  получаем на основе метода наименьших квадратов с помощью  $\theta^{(0)}, \hat{R}^{(0)}$ . Матрица  $A(\theta^{(0)})$  – матрица векторов направленности и представима в следующем виде:

$$A(\theta^{(0)}) = [a(\theta_1^{(0)}), \dots, a(\theta_K^{(0)})], \quad (20)$$

где  $a(\theta_k^{(0)})$  – вектор направленности для источника  $k$ . Перед применением МНК каждый такой вектор отнормируем:

$$\check{a}(\theta_k^{(0)}) = \frac{a(\theta_k^{(0)})}{\|a(\theta_k^{(0)})\|}, k = 1, \dots, K, \quad (21)$$

сформируем из них нормированную матрицу векторов направленности:

$$\check{A}(\theta^{(0)}) = [\check{a}(\theta_1^{(0)}), \dots, \check{a}(\theta_K^{(0)})], \quad (22)$$

применяем МНК для получения нормированной ковариации мощностей:

$$\check{\Gamma}^{(0)} = \mathcal{D}[\check{A}(\theta^{(0)})^+ (\hat{R}^{(0)} - \Lambda)(\check{A}(\theta^{(0)})^+)^*], \quad (23)$$

где  $\mathcal{D}[\cdot]$  – диагональное приближение матрицы,  $(\cdot)^+$  – псевдообратная матрица. Такой подход не гарантирует, что все элементы матрицы на главной диагонали будут неотрицательными, поэтому используем следующую корректировку:  $\check{\Gamma}_{ll}^{(0)} = \max(\check{\Gamma}_{ll}^{(0)}, \varepsilon), l = 1, \dots, L$ . Переходим к ненормированной мощности:

$$\Gamma_l^{(0)} = \frac{\check{\Gamma}_{ll}^{(0)}}{\|a(\theta_k^{(0)})\|_l}, l = 1, \dots, L. \quad (24)$$

Требуется гарантировать, что при выбранной инициализации на Е-шаге не будет получена условная ковариация сигналов, не являющаяся положительной определенной. Вычисляем оценку условной ковариации сигналов, используя начальную оценку, и проверяем, выполняется ли свойство неотрицательной определенности:

$$\Gamma^{(0)} - (\Gamma^{(0)})^* A(\theta^{(0)})^* (\hat{R}^{(0)})^{-1} A(\theta^{(0)}) \Gamma^{(0)} \succeq 0, \quad (25)$$

пока это свойство не выполняется, домножаем матрицу на 0.5:  $\mathbf{\Gamma}^{(0)} = 0.5 \cdot \mathbf{\Gamma}^{(0)}$  и повторно проверяем выполнимость вышеуказанного свойства.

## Приложение Б. О корректности Е-шага

В рамках Е-шага необходимо вычислить  $\mathbb{E}[S_t|X_{t,o_t} = x_{t,o_t}]$ ,  $\text{Cov}(S_t|X_{t,o_t} = x_{t,o_t})$ . Вычисление  $\mathbb{E}[S_t|X_{t,o_t} = x_{t,o_t}]$  реализуется так:

$$\begin{aligned}\mathbb{E}[S_t|X_{t,o_t} = x_{t,o_t}] &= \mathbb{E}[\mathbb{E}[S_t|X_t]|X_{t,o_t} = x_{t,o_t}] \\ &= \mathbb{E}[\boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t | X_{t,o_t} = x_{t,o_t}] = \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbb{E}[X_t | X_{t,o_t} = x_{t,o_t}].\end{aligned}$$

Для нахождения  $\text{Cov}(S_t|X_{t,o_t} = x_{t,o_t})$  может быть использовано равенство, называемое законом полной дисперсии (Law of total variance, может быть найдено в Sheldon Ross, A first course in probability, 8th ed., 2010):

$$\text{Cov}(W) = \mathbb{E}[\text{Cov}(W|Y)] + \text{Cov}(\mathbb{E}[W|Y]). \quad (26)$$

Пусть  $\mathcal{F}_Z = \sigma(Z)$  – сигма-алгебра, порожденная  $Z$ . Тогда все числовые характеристики  $W$ , включая условные моменты и ковариации относительно  $Y$ , можно обусловить на  $\mathcal{F}_Z$ . И, соответственно, из закона полной ковариации следует:

$$\text{Cov}(W|\mathcal{F}_Z) = \mathbb{E}[\text{Cov}(W|Y, Z)|\mathcal{F}_Z] + \text{Cov}(\mathbb{E}[W|Y, Z]|\mathcal{F}_Z). \quad (27)$$

Вектора  $W, Y, Z$  предполагаются комплексными гауссовскими (случай круговой симметрии), зависимость между  $Z$  и  $Y$  линейная,  $\sigma(Z) \subseteq \sigma(Y)$ , предполагается, что  $Z = CY$ , где  $C$  – булев селектор. Для линейной гауссовой модели знание  $Z$  не уменьшает условную ковариацию  $W|Y$  и не влияет на условное математическое ожидание  $\mathbb{E}[W|Y, Z]$ , поскольку  $Z$  не содержит никакой новой информации, которой не было бы в  $Y$ :

$$\begin{aligned}\text{Cov}(W|Y, Z) &= \text{Cov}(W|Y), \\ \mathbb{E}[W|Y, Z] &= \mathbb{E}[W|Y].\end{aligned}$$

Получаем:

$$\text{Cov}(W|\mathcal{F}_Z) = \mathbb{E}[\text{Cov}(W|Y)|\mathcal{F}_Z] + \text{Cov}(\mathbb{E}[W|Y]|\mathcal{F}_Z). \quad (28)$$

Если  $Z = z$ , имеем:

$$\text{Cov}(W|Z = z) = \mathbb{E}[\text{Cov}(W|Y)|Z = z] + \text{Cov}(\mathbb{E}[W|Y]|Z = z). \quad (29)$$

В рамках исходной задачи по оцениванию DoA и ковариации сигналов,  $W$  соответствует величине  $S_t$ ,  $Y$  соответствует величине  $X_t$ ,  $Z$  соответствует величине  $X_{t,o_t}$ ,  $z$  соответствует величине  $x_{t,o_t}, t = 1, \dots, T$ .

Получаем:

$$\text{Cov}(S_t|X_{t,o_t} = x_{t,o_t}) = \mathbb{E}[\text{Cov}(S_t|X_t)|X_{t,o_t} = x_{t,o_t}] + \text{Cov}(\mathbb{E}[S_t|X_t]|X_{t,o_t} = x_{t,o_t}). \quad (30)$$

Преобразуем первое слагаемое, учитывая тот факт, что ковариация не зависит от реализации  $X_{t,o_t}$ .

$$\mathbb{E}[\text{Cov}(S_t|X_t)|X_{t,o_t} = x_{t,o_t}] = \text{Cov}(S_t|X_t) = \boldsymbol{\Gamma} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}. \quad (31)$$

Теперь преобразуем второе слагаемое:

$$\begin{aligned}\text{Cov}(\mathbb{E}[S_t|X_t]|X_{t,o_t} = x_{t,o_t}) &= \text{Cov}(\boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t | X_{t,o_t} = x_{t,o_t}) \\ &= \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \text{Cov}(X_t | X_{t,o_t} = x_{t,o_t}) \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}.\end{aligned}$$

Таким образом:

$$\text{Cov}(S_t|X_{t,o_t} = x_{t,o_t}) = \boldsymbol{\Gamma} - \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma} + \boldsymbol{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} \text{Cov}(X_t | X_{t,o_t} = x_{t,o_t}) \hat{\mathbf{R}}^{-1} \mathbf{A} \boldsymbol{\Gamma}. \quad (32)$$

Для полных наблюдений  $X_{t,o_t} = X_t$ , и, соответственно:

$$\text{Cov}(\mathbb{E}[S_t|X_t]|X_{t,o_t} = x_{t,o_t}) = \text{Cov}(\mathbb{E}[S_t|X_t]|X_t = x_t) = 0. \quad (33)$$

О выводе смешанных вторых моментов  $\mathbb{E}[X_t S_t^* | X_t = x_t]$  и  $\mathbb{E}[X_t S_t^* | X_{t,o_t} = x_{t,o_t}]$ :

$$\mathbb{E}[X_t S_t^* | X_t] = X_t \mathbb{E}[S_t^* | X_t] = X_t (\mathbf{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t)^* = X_t X_t^* \hat{\mathbf{R}}^{-1} \mathbf{A} \mathbf{\Gamma}, \quad (34)$$

$$\begin{aligned} \mathbb{E}[X_t S_t^* | X_{t,o_t} = x_{t,o_t}] &= \mathbb{E}[X_t \mathbb{E}[S_t^* | X_t] | X_{t,o_t} = x_{t,o_t}] = \mathbb{E}[X_t (\mathbf{\Gamma}^* \mathbf{A}^* \hat{\mathbf{R}}^{-1} X_t)^* | X_{t,o_t} = x_{t,o_t}] \\ &= \mathbb{E}[X_t X_t^* \hat{\mathbf{R}}^{-1} \mathbf{A} \mathbf{\Gamma} | X_{t,o_t} = x_{t,o_t}] = \mathbb{E}[X_t X_t^* | X_{t,o_t} = x_{t,o_t}] \hat{\mathbf{R}}^{-1} \mathbf{A} \mathbf{\Gamma} \end{aligned}$$

В приведенных выше переходах используется закон полного условного математического ожидания и уже полученное выражение для  $\mathbb{E}[S_t^* | X_t]$ .

## Приложение B. О реализации М-шага

Если антенная решетка является равномерной и линейной, удобно искать оптимальный  $u = \sin(\theta)$ , а затем находить  $\theta$  как  $\arcsin(u)$ . Соответственно минимизации подлежит функция

$$\mathcal{Q}_1(u|u^{(\tau-1)}) = \|\Lambda^{-1/2}(\mathbb{E}_{q(\Xi)}[XS^*] - \tilde{\mathbf{A}}(u)\mathbb{E}_{q(\Xi)}[SS^*])\|_F^2, \quad (35)$$

где

$$\tilde{\mathbf{A}}(u) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-2j\pi\frac{d}{\lambda}u_1} & e^{-2j\pi\frac{d}{\lambda}u_2} & \dots & e^{-2j\pi\frac{d}{\lambda}u_K} \\ \dots & \dots & \ddots & \vdots \\ e^{-2j\pi(L-1)\frac{d}{\lambda}u_1} & e^{-2j\pi(L-1)\frac{d}{\lambda}u_2} & \dots & e^{-2j\pi(L-1)\frac{d}{\lambda}u_K} \end{bmatrix}. \quad (36)$$

Для ускорения оптимизации можно оптимизировать не  $\mathcal{Q}_1(u|u^{(\tau-1)})$ , а суррогатную функцию  $\mathcal{G}(u|u^{(\tau-1)})$ , построенную так:

$$\mathcal{G}(u|u^{(\tau-1)}) = \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)}) + \nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})^T(u - u^{(\tau-1)}) + \frac{1}{2}(u - u^{(\tau-1)})^T \mathbf{H}(u - u^{(\tau-1)}), \quad (37)$$

где

$$\mathbf{H} = \begin{bmatrix} \max(|\nabla_1 \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})|, \varepsilon) & 0 & \dots & 0 \\ 0 & \max(|\nabla_2 \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})|, \varepsilon) & \dots & 0 \\ \dots & \dots & \ddots & \vdots \\ 0 & 0 & \dots & \max(|\nabla_K \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})|, \varepsilon) \end{bmatrix}, \quad (38)$$

причем  $\nabla_i \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})$  –  $i$ -я компонента градиента  $\mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})$ . Диагональная аппроксимация  $\mathbf{H}$  предотвращает слишком маленькие или слишком большие шаги, сохраняя численную стабильность. Теперь эту суррогатную функцию надо минимизировать (или, эквивалентно, найти направление шага  $\rho^{(\tau)} = u - u^{(\tau-1)}$ ):

$$\min_u \mathcal{G}(u|u^{(\tau-1)}). \quad (39)$$

Подставим  $u = u^{(\tau-1)} + \rho$ :

$$\mathcal{G}(u^{(\tau-1)} + \rho|u^{(\tau-1)}) = \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)}) + \nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})^T \rho + \frac{1}{2} \rho^T \mathbf{H} \rho. \quad (40)$$

Для нахождения минимума берем градиент по  $\rho$ :

$$\nabla_\rho \mathcal{G}(u^{(\tau-1)} + \rho|u^{(\tau-1)}) = \nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)}) + \mathbf{H} \rho, \quad (41)$$

при  $\nabla_\rho \mathcal{G} = 0$  будет выполняться:

$$0 = \nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)}) + \mathbf{H} \rho, \quad (42)$$

решаем относительно  $\rho^{(\tau)}$ :

$$\rho^{(\tau)} = -\mathbf{H}^{-1} \nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)}). \quad (43)$$

Важно заметить, что производная по направлению  $\nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})^T \rho^{(\tau)}$  принимает вид:

$$\nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})^T \rho^{(\tau)} = -\nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})^T \mathbf{H}^{-1} \nabla \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)}), \quad (44)$$

и поскольку  $\mathbf{H}$  – положительно определенная матрица, производная по направлению может принимать лишь неположительные значения, а значит направление  $\rho^{(\tau)}$  соответствует невозрастанию функции. Далее используется backtracking line search для гарантии невозрастания  $\mathcal{Q}_1$ :

$$u^{(\tau)} = u^{(\tau-1)} + \alpha_m \rho^{(\tau)}, \quad (45)$$

где  $\alpha_m$  – первое  $\alpha = \alpha_0 \beta^m$ ,  $m \in \mathbb{N}$ , такое что  $\mathcal{Q}_1(u^{(\tau)}|u^{(\tau-1)}) \leq \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})$  для фиксированных  $\alpha_0 > 0$ ,  $\beta \in (0; 1)$ .

В рамках программного комплекса реализуется мультистарт для поиска оптимального  $u$  на М-шаге. Указанный выше оптимизационный алгоритм запускается не только из точки  $u^{(\tau-1)}$ , но и из случайно выбранных допустимых точек, в том числе находящихся в окрестности  $u^{(\tau-1)}$ . Для выбранной начальной точки с индексом  $j$ , обновление оценки синусов угловых координат  $\tilde{u}^{(j)}$  может быть принято, только если:

1.  $\mathcal{Q}_1(\tilde{u}^{(j)}|u^{(\tau-1)}) > \mathcal{Q}_1(u^{(\tau-1)}|u^{(\tau-1)})$ ,
2.  $\mathcal{Q}_1(\tilde{u}^{(j)}|u^{(\tau-1)}) > \mathcal{Q}_1(\min(\tilde{u}^{(i)} : 1 \leq i \leq j-1)|u^{(\tau-1)})$ , при  $j > 1$ .

Оценим ковариацию сигналов  $\Gamma$ :

$$\Gamma^{(\tau)} = \arg \min_{\Gamma} \mathcal{Q}_2(\Gamma|\Gamma^{(\tau-1)}) = T \left[ \log |\Gamma| + \text{Tr}(\Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*]) \right]. \quad (46)$$

Определим точку, где производная данной функции принимает значение 0, и, таким образом, находим минимум функции:

$$\begin{aligned} \frac{\partial}{\partial \Gamma} \log(\text{Det}(\Gamma)) &= \Gamma^{-1}, \\ \frac{\partial}{\partial \Gamma} \text{Tr}(\Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*]) &= -\Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*] \Gamma^{-1}, \\ \frac{\partial \mathcal{Q}_2(\Gamma)}{\partial \Gamma} &= \Gamma^{-1} - \Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*] \Gamma^{-1}. \end{aligned}$$

Приравняем производную к нулю (функция по  $\Gamma$  выпукла):

$$\mathbf{O} = \Gamma^{-1} - \Gamma^{-1} \mathbb{E}_{q(\Xi)}[SS^*] \Gamma^{-1} \Rightarrow \Gamma^{(\tau)} = \mathbb{E}_{q(\Xi)}[SS^*].$$

Предполагая, что сигналы некоррелированы, будем использовать лишь диагональное приближение матрицы, приравнив элементы вне главной диагонали к нулю:

$$\Gamma^{(\tau)} = \mathcal{D} \left[ \mathbb{E}_{q(\Xi)}[SS^*] \right]. \quad (47)$$

Ввиду того, что М-шаг не максимизирует, а лишь улучшает УМО полного правдоподобия, представленный алгоритм является не точным ЕМ, а обобщенным (Generalized) ЕМ.

## Список литературы

- [1] Dempster A. P., Laird N. M., Rubin D. B. Maximum likelihood from incomplete data via the EM algorithm // Journal of the Royal Statistical Society: Series B (Methodological). – 1977. – Vol. 39. – No. 1. – P. 1–38.
- [2] Wu C. F. J. On the convergence properties of the EM algorithm // The Annals of Statistics. – 1983. – Vol. 11. – No. 1. – P. 95–103.